



第七讲：

凸规划与鞍点



凸集(convex set)

定义： 设 x, y 为欧式空间 E^n 中相异的两个点，则点集

$$P=\{\lambda x+(1-\lambda)y|\lambda\in R\}$$

称为通过 x 和 y 的直线.

定义： 设 $S\subseteq E^n$,若对 $\forall x^{(1)}, x^{(2)}\in S$ 及 $\forall \lambda\in [0,1]$,都有

$$\lambda x^{(1)}+(1-\lambda)x^{(2)}\in S$$

则称 S 为**凸集**.

设 $x^{(1)}, x^{(2)}, \dots, x^{(k)}\in S$,称

$$\lambda_1 x^{(1)}+\lambda_2 x^{(2)}+\dots+\lambda_k x^{(k)}$$

(其中 $\lambda_1+\lambda_2+\dots+\lambda_k=1$)为 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 的**凸组合**.




凸函数

凸函数： 设 S 是 E^n 中的非空凸集， $f(x)$ 是定义在 S 上的实函数，如果对于每一对 $x_1, x_2 \in S$ 及每一个 $a, 0 \leq a \leq 1$, 都有

$$f(ax_1 + (1-a)x_2) \leq af(x_1) + (1-a)f(x_2)$$

则称函数 $f(x)$ 为 S 上的凸函数. 上式中, 若 \leq 变为 $<$, 则称为严格凸函数。

若 $-f(x)$ 为 S 的凸函数, 则称 $f(x)$ 为 S 上的**凹函数**.





凸函数性质

(1) 设 $f_1(x)$, $f_2(x)$ 是凸集 S 上的凸函数, 则函数 $f_1(x)+f_2(x)$ 在 S 上也是凸函数。

(2) 设 $f(x)$ 是凸集 S 上的凸函数, 则对任意的 $a \geq 0$, 函数 $af(x)$ 是凸的。

推广: 设 $f_1(x)$, $f_2(x)$, \dots , $f_k(x)$ 是凸集 S 上的凸函数, $a_i \geq 0$, 则 $a_1f_1(x)+a_2f_2(x)+\dots+a_kf_k(x)$ 也是凸集 S 上的凸函数。

(3) 设 $f(x)$ 是凸集 S 上的凸函数, 对每一个实数 c , 则集合(level set)

$$S_c = \{x \mid x \in S, f(x) \leq c\} \text{ 是凸集。}$$

(4) 设 S 是 E^n 中的非空凸集, f 是定义在 S 上的凸函数, 则 f 在 S 上的局部极小点是整体极小点, 且极小点的集合是凸集。



证明: 设 \bar{x} 是 f 在 S 中的局部极小点, 既存在 \bar{x} 的 $\varepsilon > 0$ 邻域 $N_\varepsilon(\bar{x})$

使得对 $\forall x \in S \cap N_\varepsilon(\bar{x})$, 有 $f(x) \geq f(\bar{x})$ 。

若 \bar{x} 不是整体极小点, 则 $\exists x^{(0)} \in S$ 使 $f(\bar{x}) > f(x^{(0)})$,

$\because S$ 是凸集, \therefore 对 $\forall \lambda \in (0, 1)$ 有 $\lambda x^{(0)} + (1 - \lambda)\bar{x} \in S$,

$\because f$ 是 S 上的凸函数,

$$\therefore f(\lambda x^{(0)} + (1 - \lambda)\bar{x}) \leq \lambda f(x^{(0)}) + (1 - \lambda)f(\bar{x})$$

$$< \lambda f(\bar{x}) + (1 - \lambda)f(\bar{x}) = f(\bar{x})$$

当 λ 取得充分小时, 可使 $\lambda x^{(0)} + (1 - \lambda)\bar{x} \in S \cap N_\varepsilon(\bar{x})$,

这与 \bar{x} 为局部极小点矛盾,

$\therefore \bar{x}$ 是 f 在 S 上的整体极小点。

f 在 S 上的极小值也是它在 S 上的最小值。

极小点集合为 $\Gamma_a = \{x \mid x \in S, f(x) \leq a\}$,

则由性质 (3), Γ_a 为凸集。



凸函数的判别

梯度: $\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$

Hesse矩阵:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \dots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \dots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

$$f(x) = \frac{1}{2} x^T A x$$

$$+ b^T x + c$$

$$\nabla f(x) = A x + b$$

$$\nabla^2 f(x) = A$$



凸性

凸函数的充要条件

定理（一阶充要条件） 设 S 是 E^n 中非空开凸集， $f(x)$ 是定义在 S 上的可微函数，则 $f(x)$ 为凸函数的充要条件是对任意两点 $x^{(1)}, x^{(2)} \in S$ ，有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)});$$

$f(x)$ 为严格凸函数的充要条件是对任意互不相同两点 $x^{(1)}, x^{(2)} \in S$ ，有

$$f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$



证明

“ \Rightarrow ” 设 f 是 S 上的凸函数, 则对 $\forall x^{(1)}, x^{(2)} \in S$ 及 $\lambda \in (0, 1)$, 有

$$f(\lambda x^{(2)} + (1-\lambda)x^{(1)}) \leq \lambda f(x^{(2)}) + (1-\lambda)f(x^{(1)})$$

$$\text{即 } \frac{f(x^{(1)} + \lambda(x^{(2)} - x^{(1)})) - f(x^{(1)})}{\lambda} \leq f(x^{(2)}) - f(x^{(1)})$$

令 $\lambda \rightarrow 0^+$, 由 f 的可微性, 得 f 在点 $x^{(1)}$ 关于方向 $x^{(2)} - x^{(1)}$ 的方向导数

$$Df(x^{(1)}; x^{(2)} - x^{(1)}) = \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}) \leq f(x^{(2)}) - f(x^{(1)}),$$

$$\Rightarrow f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$



“ \Rightarrow ”当 f 是 S 上的严格凸函数时, 对 $\forall x^{(1)}, x^{(2)} \in S$ 及 $x^{(1)} \neq x^{(2)}$,

取 $\lambda = \frac{1}{2}$, 则 $y = \frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} \in S$ 且

$$f(y) = f\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)}\right) < \frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}).$$

$\therefore f$ 是凸函数,

$$\therefore f(y) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (y - x^{(1)}).$$

$$\therefore \frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (y - x^{(1)})$$

$$= f(x^{(1)}) + \frac{1}{2}\nabla f(x^{(1)})^T (x^{(2)} - x^{(1)})$$

$$\therefore f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$



‘ \Leftarrow ’ 设对 $\forall x^{(1)}, x^{(2)} \in S$, 有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})(x^{(2)} - x^{(1)}).$$

$\forall \lambda \in (0, 1)$, 令 $y = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$, 则 $y \in S$ 。

由假设, 对 $x^{(1)}, y \in S$ 及 $x^{(2)}, y \in S$ 有

$$f(x^{(1)}) \geq f(y) + \nabla f(y)^T (x^{(1)} - y)$$

$$f(x^{(2)}) \geq f(y) + \nabla f(y)^T (x^{(2)} - y)$$

$$\therefore \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)})$$


$$\geq f(y) + \nabla f(y)^T (\lambda x^{(1)} + (1 - \lambda)x^{(2)} - y)$$

$$= f(y) = f(\lambda x^{(1)} + (1 - \lambda)x^{(2)})$$

$\therefore f$ 是凸函数。



几何意义



$f(x)$ 是凸函数当且仅当任意点处的切线增量不超过函数的增量。

推论： 设 S 是 E^n 中的凸集， $\bar{x} \in S$, $f(x)$ 是定义在 E^n 上的凸函数，且在点 \bar{x} 可微，则对任意 $x \in S$ ，有

$$f(x) \geq f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x})$$



定理(二阶充要条件): 设 S 是 E^n 中非空开凸集, $f(x)$ 是定义在 S 上的二次可微函数, 则 $f(x)$ 为凸函数的充要条件是对任意 $x \in S$, $f(x)$ 在 x 处的Hessian矩阵 $\nabla^2 f(x)$ 是半正定的。



证明: " \Rightarrow " 设 f 是 S 上的凸函数, 对任意 $\bar{x} \in S$

$\because S$ 是开集, 则对 $\forall x \in E^n$, $\exists \delta > 0$ 使当 $\lambda \in (0, \delta)$, 有 $\bar{x} + \lambda x \in S$ 。

$$\therefore f(\bar{x} + \lambda x) \geq f(\bar{x}) + \lambda \nabla f(\bar{x})^T x \quad (1)$$

$\because f$ 在点 $\bar{x} \in S$ 二次可微,

$$\therefore f(\bar{x} + \lambda x) = f(\bar{x}) + \lambda \nabla f(\bar{x})^T x + \frac{1}{2} \lambda^2 x^T \nabla^2 f(\bar{x}) x + \lambda^2 \|x\|^2 a \quad (2)$$

其中 $\lim_{\lambda \rightarrow 0} a = 0$ 。

由(1),(2)得, $\frac{1}{2} \lambda^2 x^T \nabla^2 f(\bar{x}) x + \lambda^2 \|x\|^2 a \geq 0$ 。

两边除以 λ^2 后, 令 $\lambda \rightarrow 0$, 得, $x^T \nabla^2 f(\bar{x}) x \geq 0$ 。



" \Leftarrow " 设 $\nabla^2 f(x)$ 在任意点 $x \in S$ 半正定, 对 $\forall x, \bar{x} \in S$,
由带Lagrange余项的二阶Taylor展开式, 得

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\xi) (x - \bar{x})$$

其中 $\xi = \lambda \bar{x} + (1 - \lambda)x$, $\lambda \in (0, 1)$

因为 S 是凸集, 所以 $\xi \in S$, 又 $\nabla^2 f(x)$ 半正定,

$$\therefore \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\xi) (x - \bar{x}) \geq 0$$

$$\Rightarrow f(x) \geq f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x})$$

$\therefore f$ 是凸函数。



定理： 设 S 是 E^n 中非空开凸集， $f(x)$ 是定义在 S 上的二次可微函数，如果对任意 $x \in S$ ，有 f 在 x 处的 *Hessian* 矩阵 $\nabla^2 f(x)$ 正定，则 $f(x)$ 为严格凸函数。

对二次函数 $f(x) = \frac{1}{2} x^T A x + b x + c$,

若 A 正定，则 $f(x)$ 为严格凸函数；

若 A 半正定，则 $f(x)$ 为凸函数。



例：判断下列函数是否为凸函数.

$$(1) f(x_1, x_2) = x_1^2 - 2x_1x_2 + x_2^2 + x_1 + x_2$$

$$(2) f(x_1, x_2) = x_1 e^{-(x_1 + x_2)}.$$



定理： 设 $f(x)$ 是定义在凸集 S 上的可微凸函数，若 $\exists x^* \in S$ ，
使对 $\forall x \in S$ ，都有

$$\nabla f(x^*)^T (x - x^*) \geq 0,$$

则 x^* 是 $f(x)$ 在凸集 S 上的全局极小点。

证明： 对 $\forall x \in S$ ，因为 $f(x)$ 是凸函数，所以有

$$f(x) \geq f(x^*) + \nabla f(x^*)^T (x - x^*)$$

$$\because \nabla f(x^*)^T (x - x^*) \geq 0$$

$$\therefore f(x) \geq f(x^*)$$

$\Rightarrow x^*$ 为全局极小点。



凸规划

- 凸规划：求凸函数在凸集上的极小点。

$$\min f(x)$$

$$s.t. \quad g_i(x) \geq 0, i = 1, \dots, m$$

$$h_j(x) = 0, j = 1, \dots, l$$

若 $f(x)$ 是凸函数， $g_i(x)(i = 1, \dots, m)$ 是凹函数，
 $h_j(x)(j = 1, \dots, l)$ 是线性函数，则原问题为凸规划。

性质：凸规划的局部极小点就是整体极小点，
且极小点的集合为凸集。



凸规划的最优性条件



凸规划

考虑

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & x \in \Omega \end{aligned} \tag{7.4.1}$$

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为凸函数, Ω 为非空凸集, 则称 (7.4.1) 为凸规划. 若 $f(x)$ 严格凸, 则称其为严格凸规划. 本节, 我们考虑 $f(x)$ 连续可微, 且 Ω 为非空闭凸集情形.



常见凸规划

线性规划

$$\begin{array}{ll}\min & c^T x \\ \text{s. t.} & Ax = b \\ & x \geq 0\end{array}$$

Lass

$$\begin{array}{ll}\min & \frac{1}{2} \|Ax - b\|^2 \\ \text{s. t.} & \|x\|_1 \leq s\end{array}$$

凸二次规划

$$\begin{array}{ll}\min & \frac{1}{2} x^T Q x + g^T x \\ \text{s. t.} & a_i^T x = b_i, \quad i \in \mathcal{E} \\ & a_i^T x \geq b_i, \quad i \in I\end{array} \quad Q \text{ 半正定}$$



凸规划的性质

性质1 凸规划问题的任一局部最优解为全局最优解.


证明: 设 x^* 为凸规划局部最优解, 则存在 $\delta > 0$, 对任意 $x \in N(x^*, \delta) \cap \Omega$ 都有 $f(x^*) \leq f(x)$.

反证法. 假设 x^* 不是全局最优解, 则存在 $\bar{x} \in \Omega$, 使得 $f(\bar{x}) < f(x^*)$.

考虑线段 $[\bar{x}, x^*]$ 上一点 $y := \lambda \bar{x} + (1 - \lambda)x^*$, $\lambda \in (0, 1)$, 由凸函数定义

$$\begin{aligned} f(y) &\leq \lambda f(\bar{x}) + (1 - \lambda)f(x^*) \\ &< \lambda f(x^*) + (1 - \lambda)f(x^*) = f(x^*) \end{aligned}$$

当 λ 充分小时, $y \in N(x^*, \delta) \cap \Omega$ 且 $f(y) < f(x^*)$, 这与 x^* 为局部最优解矛盾. 证毕





凸规划的性质

性质2 凸规划问题 (7.4.1) 的解集为凸集.

证明: 设最优解集为 S , 若 $S = \emptyset$, 结论显然. 若 $S \neq \emptyset$, 设 $x^* \in S$, 最优解集可表示为

$$S := \{x \in \Omega | f(x) \leq f(x^*)\} = \Omega \cap \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$$

由于 Ω 为凸集, 凸函数的水平集 $\mathcal{L}(x^*) = \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$ 为凸集, 根据两个凸集交集仍为凸集可知

$$S = \Omega \cap \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$$

为凸集. 证毕



凸规划的性质

性质3 问题 (7.4.1) 为严格凸规划问题时, 若存在最优解, 则最优解唯一.

证明: 假设 x^*, y^* 均为 (7.4.1) 最优解, 且 $x^* \neq y^*$


取 $z^* = \frac{1}{2}(x^* + y^*)$, 则 $z \in \Omega$. 根据严格凸函数的定义有

$$f(z^*) < \frac{1}{2}f(x^*) + \frac{1}{2}f(y^*) = f(x^*)$$

与 x^* 为最优解矛盾. 证毕



严格凸规划并不一定存在最优解.



$$\min_{x \in \mathbb{R}} e^{-x}$$

$$(e^{-x})'' = e^{-x}$$



凸规划的性质

性质4 凸规划问题 (7.4.1) 的全局最优解与稳定点等价.

证明: 设 x^* 为凸规划全局最优解, 由定理7.1.2, x^* 为稳定点
反之若 x^* 为稳定点, 即对任意 $x \in \Omega$,

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0.$$

利用凸函数的性质得

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle \geq f(x^*),$$

故 x^* 为全局最优点. 证毕

定理 7.1.2 若约束优化问题的可行域为非空闭凸集, 则其任一局部最优解为其稳定点。

稳定点 \longleftrightarrow 全局最优解 \longleftrightarrow 局部最优解




等式与不等式约束下的凸规划

带有等式和不等式约束的凸规划可表示成如下形式

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E}, \\ & c_i(x) \geq 0, \quad i \in I \end{aligned} \quad (7.4.2)$$

$$\begin{aligned} i \in I, \Omega_i &:= \{x \in \mathbb{R}^n | c_i(x) \geq 0\} \\ &= \{x \in \mathbb{R}^n | -c_i(x) \leq 0\} = \mathcal{L}_{-c_i}(0) \end{aligned}$$

$-c_i(x)$ 为凸函数




Ω_i 为凸集



$$\begin{aligned} i \in \mathcal{E}, \Omega_i &:= \{x \in \mathbb{R}^n | c_i(x) = 0\} \\ &= \{x \in \mathbb{R}^n | -c_i(x) \leq 0\} \cap \{x \in \mathbb{R}^n | c_i(x) \leq 0\} \\ &= \mathcal{L}_{c_i}(0) \cap \mathcal{L}_{-c_i}(0) \end{aligned}$$

$-c_i(x), c_i(x)$ 为凸函数



Ω_i 为凸集



约束集

$$\Omega = \bigcap_{i \in \mathcal{E} \cup I} \Omega_i$$

为凸集



凸规划的等式约束为线性约束，不等式约束函数为凹函数。



Slater约束规格

定义7.4.1 对凸规划问题 (7.4.2) , 若存在可行点 \bar{x} 使得

$$c_i(\bar{x}) > 0, \quad i \in I$$

则称该规划问题满足Slater约束规格, 又称Slater条件.



可行点 \bar{x} 是不等式约束集的严格内点.



针对凸规划(7.4.2) , 利用Slater约束规格, 可建立KKT条件.



Slater约束规格

定理7.4.1 对凸规划问题 (7.4.2) , 若Slater约束规格成立, 则最优值点为KKT点.

仅证: Slater约束规格 \longrightarrow M-F约束规格

即证:

存在可行点 \bar{x} 使得 $c_i(\bar{x}) > 0, i \in I$

存在可行点 \bar{x} 使得 $\nabla c_i(\bar{x}), i \in \mathcal{E}$ 线性无关, 且存在非零向量 $s \in R^n$ 使得 $s^T \nabla c_i(\bar{x}) = 0, i \in \mathcal{E}, s^T \nabla c_i(\bar{x}) > 0, i \in I(\bar{x})$

定理7.2.2

局部极小+M-F约束规格 \longrightarrow KKT点



Slater与M-F约束规格

引理 7.4.1 对凸规划问题 (7.4.2) , 若Slater约束规格成立, 则对任意 $x \in \Omega$, 必存在非零向量 $s \in R^n$ 使得

$$s^T \nabla c_i(x) = 0, i \in \mathcal{E}, s^T \nabla c_i(x) > 0, i \in \mathcal{I}(x).$$

证明 由Slater约束规格, 存在 $\bar{x} \in \Omega$ 使

$$c_i(\bar{x}) = 0, i \in \mathcal{E}; \quad c_i(\bar{x}) > 0, i \in \mathcal{I}.$$


对任意的 $x \in \Omega$, 令 $s = \bar{x} - x$. 对 $i \in \mathcal{E}$, 由于 $c_i(x)$ 为线性函数, 所以

$$0 = c_i(\bar{x}) = c_i(x + s) = c_i(x) + s^T \nabla c_i(x) = s^T \nabla c_i(x).$$

对 $i \in \mathcal{I}(x)$, 由于 $c_i(x)$ 为凹函数, 所以

$$0 < c_i(\bar{x}) = c_i(x + s) \leq c_i(x) + s^T \nabla c_i(x) = s^T \nabla c_i(x),$$

即 s 满足命题结论.





弱Slater约束规格

定义7.4.2 对凸规划问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E}, \\ & c_i(x) \geq 0, \quad i \in I_1 \cup I_2 \end{aligned} \quad (7.4.3)$$

其中, $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为连续可微凸函数, $c_i(x), i \in \mathcal{E} \cup I_1$ 为线性函数, $c_i(x), i \in I_2$ 为非线性连续可微凹函数, 若存在 $\bar{x} \in \Omega$ 使得

$$c_i(\bar{x}) > 0, i \in I_2,$$

则称该约束优化问题满足弱Slater约束规格.



弱Slater约束规格

定理7.4.2 对凸规划问题(7.4.3), 如果弱Slater约束规格成立, 则最优值点为KKT点.

证明:

x^* 为凸规划问题 (7.4.3) 的最优值点



仿照引理7.4.1

$\exists s \in \mathbb{R}^n, s^T \nabla c_i(x^*) = 0, i \in \mathcal{E}; s^T \nabla c_i(x^*) \geq 0, i \in I_1(x^*); s^T \nabla c_i(x^*) > 0, i \in I_2(x^*) \longrightarrow s \text{ 为可行方向}$



$\{s \in \mathbb{R}^n | s^T \nabla c_i(x^*) = 0, i \in \mathcal{E}; s^T \nabla c_i(x^*) \geq 0, i \in I_1(x^*); s^T \nabla c_i(x^*) > 0, i \in I_2(x^*); s^T \nabla f(x^*) < 0\} = \emptyset$



推论1.4.3

x^* 为KKT点

推论1.4.3 设向量组 $a_i \in \mathbb{R}^n, i \in \mathcal{E} \cup \mathcal{I}_1 \cup \mathcal{I}_2$ 和向量 $b \in \mathbb{R}^n$ 满足

$$\{x \in \mathbb{R}^n \mid a_i^T x = 0, i \in \mathcal{E}; a_i^T x \geq 0, i \in \mathcal{I}_1; a_i^T x > 0, i \in \mathcal{I}_2\}$$

非空. 则集合

$$\{x \in \mathbb{R}^n \mid a_i^T x = 0, i \in \mathcal{E}; a_i^T x \geq 0, i \in \mathcal{I}_1; a_i^T x > 0, i \in \mathcal{I}_2; b^T x < 0\} = \emptyset$$

的充分必要条件是存在满足 $\lambda_i \geq 0, i \in \mathcal{I}_1 \cup \mathcal{I}_2$ 的数组 λ 使得

$$b = \sum_{i \in \mathcal{E} \cup \mathcal{I}_1 \cup \mathcal{I}_2} \lambda_i a_i.$$



常见约束规格

约束均为线性函数

$$c_i(x) = a_i^T x + b_i$$

线性无关

$$\nabla c_i(x^*), i \in \mathcal{E} \text{ 线性无关}$$

M-F约束规格

$\nabla c_i(x^*), i \in \mathcal{E}$ 线性无关, 且存在非零向量

$s \in R^n$ 使得

$$s^T \nabla c_i(x^*) = 0, i \in \mathcal{E}, s^T \nabla c_i(x^*) > 0, i \in I(x^*)$$

Slater约束规格

$$\exists \hat{x}, s. t. \begin{cases} c_i(\hat{x}) = 0, i \in \mathcal{E} \\ c_i(\hat{x}) > 0, i \in I \end{cases}$$

弱Slater约束规格

$$\exists \hat{x}, s. t. \begin{cases} c_i(\hat{x}) = 0, i \in \mathcal{E} \\ c_i(\hat{x}) \geq 0, i \in I_1 \\ c_i(\hat{x}) > 0, i \in I_2 \end{cases}$$




北京交通大学

Lagrange函数的鞍点




回顾：鞍点 (saddle point)

定义：对于无约束优化问题 $\min_{x \in \mathbb{R}^n} f(x)$ ，若 $\nabla f(x^*) = 0$ ，则 x^* 称为 $f(x)$ 的一个驻点（稳定点）。既不是极小值点，也不是极大值点的驻点称为鞍点。但是，...



$$f(x) = x^3$$



$$f(x) = x_1^2 - x_2^2$$



回顾：等式约束优化问题最优性条件

在正则性条件下，等式约束优化问题的一阶最优性条件可以用Lagrange函数的梯度描述.

$$\begin{cases} \nabla_x L(x^*, \lambda^*) = 0, \\ \nabla_\lambda L(x^*, \lambda^*) = c(x^*) = 0. \end{cases}$$



(x^*, λ^*) 构成Lagrange函数的稳定点



其中 x^* 为最优解， λ^* 为最优Lagrange乘子.



(x^*, λ^*) 是哪 种 类 型 稳 定 点？

局部最
优？

鞍点？



约束优化与Lagrange函数

考虑约束优化问题

$$\min\{f(x) | c_i(x) = 0, i \in \mathcal{E}; c_i(x) \geq 0, i \in I\} \quad (7.2.2)$$

则相应的Lagrange函数为

$$L(x, \lambda, \mu) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i c_i(x) - \sum_{i \in I} \mu_i c_i(x) \quad \forall \lambda \in \mathbb{R}^{|\mathcal{E}|}, \forall \mu \in \mathbb{R}_+^{|I|}, \forall x \in \mathbb{R}^n$$



Lagrange函数的鞍点

定义7.3.1 对约束优化问题

$$\min\{f(x) | c_i(x) = 0, i \in \mathcal{E}; c_i(x) \geq 0, i \in I\} \quad (7.2.2)$$

若存在 $x^* \in \mathbb{R}^n$, $\lambda^* \in \mathbb{R}^{|\mathcal{E}|}$, 以及 $\mu^* \in \mathbb{R}_+^{|I|}$, ($\mu_i^* \geq 0, i \in I$) 满足

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*), \quad \forall \mu^* \in \mathbb{R}_+^{|I|}, \forall \lambda \in \mathbb{R}^{|\mathcal{E}|}, \forall x \in \mathbb{R}^n$$

则 (x^*, λ^*, μ^*) 称为该约束优化问题Lagrange函数的鞍点.



$$L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*), \forall x \in \mathbb{R}^n$$



$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*), \forall \lambda \in \mathbb{R}^{|\mathcal{E}|}, \mu_i \geq 0, i \in I$$



对于不等式约束的Lagrange乘子有非负约束

$$x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*)$$

$$(\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|I|}}} L(x^*, \lambda, \mu)$$



鞍点与KKT点对

定理7.3.1 设 (x^*, λ^*, μ^*) 为约束优化问题(7.2.2)的Lagrange函数的鞍点, 则 (x^*, λ^*, μ^*) 是该约束优化问题的一个KKT点对.

鞍点

$$x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*)$$

$$(\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|\mathcal{I}|}}} L(x^*, \lambda, \mu)$$



KKT对

$$\nabla_x L(x^*, \lambda^*, \mu^*) = 0,$$

$$\mu_i^* \geq 0, c_i(x^*) \geq 0, \mu_i^* c_i(x^*) = 0, \quad \forall i \in \mathcal{I},$$

$$c_i(x^*) = 0, \quad \forall i \in \mathcal{E}$$



鞍点与KKT点对

证明:

■ $x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*) \quad \Rightarrow \quad \nabla_x L(x^*, \lambda^*, \mu^*) = 0,$

■ $\lambda^* \in \operatorname{argmax}_{\lambda \in \mathbb{R}^{|\mathcal{E}|}} L(x^*, \lambda, \mu^*) \quad \Rightarrow \quad \nabla_\lambda L(x^*, \lambda^*, \mu^*) = -c_i(x^*) = 0, \forall i \in \mathcal{E} \quad \Leftrightarrow \quad c_i(x^*) = 0, \quad \forall i \in \mathcal{E}$

■ $\mu^* \in \operatorname{argmax}_{\mu \in \mathbb{R}_+^{|\mathcal{I}|}} L(x^*, \lambda^*, \mu) \quad \Rightarrow \quad \begin{cases} -\nabla_\mu L(x^*, \lambda^*, \mu^*) - \gamma = 0 \\ \gamma_i \geq 0, \mu_i^* \geq 0, \gamma_i \mu_i^* = 0, \quad i \in I \end{cases} \quad \Rightarrow \quad \gamma_i = c_i(x^*), \quad i \in I$

$\mu^* \in \operatorname{argmin}_{\mu \in \mathbb{R}_+^{|\mathcal{I}|}} -L(x^*, \lambda^*, \mu)$

$\mu_i^* \geq 0, c_i(x^*) \geq 0, \mu_i^* c_i(x^*) = 0, \quad \forall i \in I.$



鞍点与全局最优解

定理7.3.2 设 (x^*, λ^*, μ^*) 为约束优化问题(7.2.2)的Lagrange函数的鞍点, 则 x^* 是该约束优化问题的全局最优解.

证明: 由定理7.3.1, x^* 为优化问题(7.2.2)的K-T点, 利用鞍点定义, 对任意 $x \in \Omega$,

$$L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*)$$

$$f(x^*) - \sum_{i \in \mathcal{E}} \lambda_i^* c_i(x^*) - \sum_{i \in I} \mu_i^* c_i(x^*) \leq f(x) - \sum_{i \in \mathcal{E}} \lambda_i^* c_i(x) - \sum_{i \in I} \mu_i^* c_i(x)$$

即

KKT条件互补性

$x \in \Omega, c_i(x) = 0, \forall i \in \mathcal{E}$

$$f(x^*) \leq f(x) - \sum_{i \in I} \mu_i^* c_i(x) \leq f(x)$$

从而 x^* 为约束优化问题(7.2.2)全局最优解.

$c_i(x) \geq 0, \mu_i^* \geq 0$



鞍点的存在性

例：考虑非线性规划 $\min_{x \in \mathbb{R}} \{x^3 \mid -x^2 \geq 0\}$

该问题最优解 $x^* = 0$. 相应的Lagrange函数为

$$L(x, \lambda) = x^3 + \lambda x^2$$

根据鞍点定义，要寻找 $\lambda^* \geq 0$ 对任意 $x \in \mathbb{R}, \lambda \geq 0$ 都有

$$L(x^*, \lambda) \leq L(x^*, \lambda^*) \leq L(x, \lambda^*),$$

即满足

$$x^{*3} + \lambda x^{*2} \leq x^{*3} + \lambda^* x^{*2} \leq x^3 + \lambda^* x^2,$$

等价于满足

$$x^3 + \lambda^* x^2 \geq 0, \forall x \in \mathbb{R}$$

可以验证任意给定 $\lambda^* \geq 0$ ，均不满足上式. 因为若 $\lambda^* = 0$ ，则 $x = -1$ 时，上式不成立；

若 $\lambda^* > 0$ ，则 $x = -2\lambda^*$ 时，上式不成立. 因此该优化问题Lagrange函数不存在鞍点.



鞍点要比全局最优解更强，但它不一定存在，并且难以求解，所以通常不希望求解鞍点.



最优性条件关系





凸规划：KKT点对与鞍点

定理7.4.3 若 (x^*, λ^*, μ^*) 凸规划问题 (7.4.2) 的KKT点对, 则 (x^*, λ^*, μ^*) 为Lagrange函数的鞍点.

证明:

■ $x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*)$

$$L(x, \lambda^*, \mu^*) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i^* c_i(x) - \sum_{i \in \mathcal{I}} \mu_i^* c_i(x) \quad \text{关于 } x \in \mathbb{R}^n \text{ 为凸函数}$$



$$L(x, \lambda^*, \mu^*) \geq L(x^*, \lambda^*, \mu^*) + (x - x^*)^T \nabla_x L(x^*, \lambda^*, \mu^*) = L(x^*, \lambda^*, \mu^*) \quad =0$$

(x^*, λ^*, μ^*) 为K-T对

■ $(\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|\mathcal{I}|}}} L(x^*, \lambda, \mu)$


对任意 $\lambda \in \mathbb{R}^{|\mathcal{E}|}, \mu \in \mathbb{R}_+^{|\mathcal{I}|}$

$$\begin{aligned} L(x^*, \lambda, \mu) - L(x^*, \lambda^*, \mu^*) &= - \sum_{i \in \mathcal{E}} \lambda_i c_i(x^*) - \sum_{i \in \mathcal{I}} \mu_i c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i^* c_i(x^*) + \sum_{i \in \mathcal{I}} \mu_i^* c_i(x^*) \\ &= - \sum_{i \in \mathcal{I}} \mu_i c_i(x^*) \leq 0 \end{aligned} \quad \begin{matrix} =0 & =0 & =0 \\ \text{互补} \end{matrix}$$



凸规划：KKT点与全局最优解

对于凸规划问题 (7.4.2)



定理7.4.4 凸规划问题 (7.4.2) 的KKT点为其全局最优解.



总结：凸规划最优性条件

对于凸规划问题 (7.4.2)

